FACULDADE DE INFORMÁTICA E ADMINISTRAÇÃO PAULISTA (FIAP)

CHALLENGE Sanofi SPRINT 4

SÃO PAULO – SP

2024

BACHARELADO EM ENGENHARIA DA COMPUTAÇÃO – 1º SEMESTRE

Inteligência Artificial e Computacional

Vitor de Andrade Ferreira Dias – RM 957132

Guilherme Macario da Silva - RM: 84057

Kaique Carvalho da Silva - RM: 93040

BENJAMIM LUCAS RODRIGUES GONÇALO - RM96026

SÃO PAULO – SP

2024

Solução de Integração de Dados para Sanofi

Descrição Geral

A solução proposta visa integrar dados extraídos do sistema SAP com um banco de dados SQL Server, utilizando scripts em Jupyter Notebook para realizar operações de ETL (Extração, Transformação e Carga). Esta integração permitirá que a Sanofi centralize suas informações de maneira eficiente, automatizando processos que atualmente exigem intervenção manual, resultando em maior precisão e agilidade na análise de dados. Além disso, os dados processados serão exportados para uma planilha Excel via ODBC, facilitando a criação de relatórios e visualizações.

Objetivos Principais

1. **Automatizar o Processo de Integração de Dados:**
    - **Desenvolver um script em Python que será responsável por extrair dados do SAP, realizar as devidas transformações e armazená-los no banco de dados SQL Server. Isso significa que a coleta de dados, que anteriormente poderia ser um processo manual e propenso a erros, será feita automaticamente, garantindo mais eficiência.**
2. **Exportar os Dados do SQL Server para o Excel:**
    - **Utilizar a interface ODBC para conectar ao banco de dados SQL e exportar os dados para um arquivo Excel. Esta funcionalidade permitirá que os analistas da Sanofi continuem utilizando ferramentas familiares para relatórios, enquanto os dados são extraídos de forma mais organizada e precisa.**
3. **Centralizar os Dados em um Repositório Confiável:**
    - **Garantir que todos os dados extraídos e transformados estejam disponíveis em um banco de dados relacional, permitindo futuras análises e consultas. A centralização das informações facilitará o acesso e a integridade dos dados, tornando-os mais acessíveis para os usuários.**

Ferramentas e Tecnologias Utilizadas

- **Python (Jupyter Notebook):**
    - **Uma linguagem de programação versátil e fácil de usar, ideal para automação de processos. O Jupyter Notebook proporciona um ambiente interativo que permite executar scripts e visualizar resultados em tempo real.**
- **ODBC (Open Database Connectivity):**
    - **Um protocolo padrão que permite que aplicativos se conectem a bancos de dados independentes de suas plataformas. No nosso contexto, o ODBC atua como um "intermediário" que facilita a comunicação entre o Excel e o SQL Server.**
- **SQL Server:**

- **Um sistema de gerenciamento de banco de dados relacional desenvolvido pela Microsoft. Ele armazena e organiza dados de maneira estruturada, permitindo consultas eficientes e segurança de dados.**

- **Excel:**
  - **Uma ferramenta amplamente utilizada para manipulação de dados, criação de gráficos e relatórios. O Excel será utilizado para apresentar os dados processados de forma visual e interativa.**

- **SAP:**
  - **Um software empresarial que integra diversas áreas de negócio, como finanças, logística e recursos humanos. Neste projeto, utilizamos o SAP como a fonte primária de dados.**

Estrutura da Solução

1. **Extração de Dados (E):**
   - **Utilizamos bibliotecas como win32com.client e pyodbc para extrair dados do SAP. O win32com.client permite a automação de aplicações Windows, facilitando a interação com o SAP, enquanto o pyodbc estabelece a conexão com o SQL Server.**
2. **Transformação dos Dados (T):**
   - **No ambiente Jupyter, os dados são processados e limpos. Isso envolve a remoção de duplicatas, o preenchimento de valores ausentes e a formatação adequada, assegurando que os dados estejam prontos para a carga no SQL Server.**
3. **Carga dos Dados (L):**
   - **Com a transformação completa, utilizamos a conexão ODBC para carregar os dados processados no banco de dados SQL Server. Isso envolve a inserção de dados em tabelas apropriadas, garantindo que a estrutura do banco de dados esteja alinhada com as necessidades de análise.**
4. **Exportação para Excel:**
   - **Uma vez que os dados estão no SQL Server, utilizamos o ODBC novamente para exportar os dados em formato Excel. Essa etapa garante que as informações estejam facilmente acessíveis para os usuários finais, permitindo a criação de relatórios dinâmicos.**

Fluxo de Trabalho

1. **Execução do Script Jupyter:**
   - **O processo se inicia com a execução do script em Jupyter, que automatiza a extração dos dados do SAP através da biblioteca win32com.client.**
   - **Em seguida, os dados são transformados e processados no Jupyter, prontos para serem carregados no SQL Server.**

2. **Conexão ao Banco de Dados SQL Server:**
    - **Usando ODBC, o script conecta-se ao banco de dados SQL Server, permitindo que os dados transformados sejam carregados nas tabelas correspondentes.**
3. **Exportação para Excel:**
    - **Finalmente, o script Python utiliza ODBC para solicitar os dados do SQL Server e gerar uma planilha Excel, que pode ser usada para análise e relatórios.**

Benefícios

- **Automação e Redução de Erros:**
    - **O processo automatizado diminui o esforço manual e possíveis erros durante a extração e transformação de dados. Com a automação, a Sanofi pode confiar que os dados estão sempre atualizados e precisos.**
- **Escalabilidade:**
    - **A solução é escalável e pode ser adaptada para lidar com diferentes conjuntos de dados e integrar-se com outras fontes no futuro, aumentando a flexibilidade da infraestrutura de dados.**
- **Rastreabilidade e Armazenamento Centralizado:**
    - **Os dados são armazenados no SQL Server, permitindo que sejam auditados, rastreados e consultados posteriormente. Isso não apenas melhora a segurança dos dados, mas também facilita a conformidade com regulamentações.**

Reflexões sobre o Desenvolvimento

Durante o desenvolvimento desta solução, percebemos que há um grande potencial para melhorar a forma como a Sanofi implementa tecnologias para seus colaboradores. O projeto se concentra no backend, permitindo que os funcionários continuem utilizando suas planilhas atuais sem interferências. Essa abordagem garante que a transição para a nova solução seja suave e sem interrupções nos processos existentes.

Além disso, a integração de tecnologias modernas pode aumentar a eficiência e a qualidade das análises realizadas, proporcionando insights mais precisos e rápidos para a tomada de decisões.

Próximos Passos

1. **Implementação do Script ETL em Ambiente de Testes:**
    - **Realizar testes rigorosos para validar a funcionalidade e a eficiência do script ETL em um ambiente controlado.**
2. **Integração com o Excel para Geração Automática dos Relatórios:**
    - **Garantir que a exportação para o Excel funcione sem problemas, permitindo que os usuários gerem relatórios automaticamente com os dados mais recentes.**

3. **Otimização do Processo para Grandes Volumes de Dados:**
    - **Identificar e implementar melhorias no desempenho do processo ETL, assegurando que ele possa lidar com grandes volumes de dados de maneira eficiente.**

Reflexões sobre o Desenvolvimento e Apresentação do Produto

Durante o desenvolvimento da solução de integração de dados para a Sanofi, tivemos a oportunidade de observar várias facetas do processo de implementação de tecnologia na empresa. Em geral, a solução proposta se mostrou eficaz e atendeu às expectativas, proporcionando uma automação robusta e eficiente para a integração entre o sistema SAP e o banco de dados SQL Server. Contudo, também enfrentamos desafios significativos que impactaram nossa abordagem.

Uma das maiores dificuldades que encontramos foi relacionada à manipulação de dados sensíveis. Ao tentar acessar informações específicas e realizar transações diretas no SAP, percebemos que não podíamos avançar profundamente devido a restrições de segurança e confidencialidade. Como resultado, optamos por gravar o script real em VBS (Visual Basic Script) para gerenciar as transações do SAP, e em seguida, fizemos a conversão desse script para Python, o que nos permitiu utilizar RPA (Automação de Processos Robóticos) para a execução das tarefas necessárias.

Esse desafio em particular forçou nossa equipe a adotar uma abordagem mais genérica para a extração e transformação dos dados. Embora a solução final tenha se mostrado perfeita em sua estrutura e funcionalidade, essa limitação nos obrigou a generalizar algumas operações, o que poderia ter um impacto na especificidade e na profundidade das análises que poderíamos oferecer inicialmente.

No entanto, a flexibilidade e a robustez da solução final foram aspectos que funcionaram muito bem. O uso de uma abordagem automatizada reduziu significativamente a necessidade de intervenção manual e minimizou o risco de erros. Além disso, a centralização dos dados em um banco de dados relacional permite um acesso mais seguro e eficiente para análises futuras.

Em resumo, apesar dos obstáculos enfrentados, a solução se revelou eficaz e alinhada aos objetivos da Sanofi. A experiência destacou a importância de uma implementação cuidadosa e adaptativa, além de reforçar a necessidade de um equilíbrio entre inovação e segurança em processos que envolvem dados sensíveis.